ĐẠI HỌC QUỐC GIA, THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

HỌC MÁY (CO3117)

BÁO CÁO BÀI TẬP LỚN

Phân loại ảnh MRI u não bằng Machine Learning truyền thống

GVHD:	TS. Huỳnh Văn Thống	
SV thực hiện:	Nguyễn Trần Anh Quân	2312845
	Bùi Ngọc Phúc	2312665
	Lê Trần Tấn Phát	2312580
	Nghiêm Nguyễn Trường An	2310013

TP Hồ Chí Minh, Tháng 04 Năm 2026

Mục lục

1 Giới thiệu **3**
1.1 Bối cảnh bài toán . . . 3
1.2 Ý nghĩa thực tiễn và học thuật . . . 3
1.3 Mục tiêu . . . 3
1.4 Kế hoạch triển khai . . . 3
1.5 Phạm vi thực hiện . . . 4

2 Tổng quan về tập dữ liệu **5**
2.1 Mô tả dữ liệu . . . 5
2.2 Góc chụp và phân phối cắt ảnh . . . 5
2.3 Quy mô và cấu trúc dữ liệu . . . 5
2.4 Một số hướng tiếp cận hiện đại cho bài toán này . . . 5
2.5 Định hướng của nhóm trong báo cáo này . . . 6

3 Phân tích khám phá dữ liệu (EDA) **7**
3.1 Cấu trúc bộ dữ liệu . . . 7
3.2 Phân phối nhãn . . . 7
3.3 Phân tích kích thước ảnh . . . 8
3.4 Phân tích kênh màu và cường độ pixel . . . 9
3.5 Phân tích kích thước file . . . 10
3.6 Trực quan mẫu dữ liệu . . . 11

4 Phương pháp thực hiện **12**
4.1 Tiền xử lý . . . 12
4.2 Trích xuất đặc trưng . . . 13
4.2.1 HOG . . . 13
4.2.2 Phương pháp SIFT trong trích xuất đặc trưng ảnh . . . 14
4.3 Giảm chiều . . . 15
4.3.1 Principal Component Analysis . . . 15
4.4 Mô hình phân loại . . . 17
4.4.1 SVM . . . 17
4.4.2 Decision Tree . . . 18
4.4.3 Random Forest . . . 19
4.4.4 XGBoost . . . 20
4.4.5 Multi-Layer Perceptron . . . 21
4.5 Tối ưu quy trình thực nghiệm . . . 22

5 Thiết kế thực nghiệm **23**
5.1 Thiết lập đánh giá . . . 23
5.2 Danh sách thực nghiệm chính . . . 23

6 Kết quả và so sánh **24**
6.1 Kết quả mục 5.1: HOG + SVM và SIFT + SVM . . . 24
6.2 Kết quả mục 5.2: HOG + Random Forest + PCA . . . 24
6.2.1 Feature Importance – Random Forest . . . 24
6.3 Kết quả mục 5.3: HOG + Decision Tree + PCA . . . 24
6.3.1 Feature Importance – Decision Tree . . . 25
6.4 Kết quả mục 5.4: HOG + SVM + PCA . . . 25

6.5 Kết quả mục 5.5: HOG + XGBoost + PCA 25
6.5.1 Feature Importance – XGBoost 25
6.6 Kết quả mục 5.6: HOG + MLP + PCA 26
6.7 Tóm tắt so sánh 26
6.8 Phân tích lỗi 27

7 Kết luận và hướng phát triển 29
7.1 Kết luận 29
7.2 Hướng phát triển 29

1 Giới thiệu

1.1 Bối cảnh bài toán

Phân loại ảnh y tế là một trong những hướng ứng dụng quan trọng của trí tuệ nhân tạo trong hỗ trợ chẩn đoán lâm sàng. Với dữ liệu ảnh cộng hưởng từ (MRI) não, việc nhận diện và phân loại tổn thương có thể giúp rút ngắn thời gian sàng lọc, hỗ trợ bác sĩ trong quá trình ra quyết định và giảm sai sót do đánh giá chủ quan.
Trong bối cảnh đó, bài toán của đề tài là phân loại ảnh MRI não thành bốn lớp: *no_tumor*, *glioma*, *meningioma* và *pituitary*. Đây là bài toán phân loại đa lớp, đòi hỏi mô hình vừa đủ khả năng phân biệt đặc trưng hình thái giữa các loại u, vừa đảm bảo độ ổn định khi dữ liệu có khác biệt về kích thước ảnh, độ sáng và nhiễu.
Trong bài tập lớn này, nhóm thực hiện xây dựng một pipeline học máy truyền thống hoàn chỉnh cho bài toán phân loại ảnh y tế, sử dụng các phương pháp trích xuất đặc trưng thủ công kết hợp với các thuật toán Machine Learning cổ điển. Cách tiếp cận này giúp tăng tính giải thích, dễ tái lập thực nghiệm và phù hợp với mục tiêu học thuật của môn học.

1.2 Ý nghĩa thực tiễn và học thuật

Đề tài có ý nghĩa ở hai khía cạnh chính:

- **Thực tiễn**: xây dựng một quy trình phân loại ảnh MRI có thể vận hành trên tài nguyên tính toán vừa phải, làm cơ sở cho các hệ thống hỗ trợ chẩn đoán ban đầu.
- **Học thuật**: làm rõ vai trò của từng thành phần trong pipeline truyền thống, đặc biệt là mối quan hệ giữa phương pháp trích đặc trưng và hiệu năng mô hình phân loại.

1.3 Mục tiêu

Mục tiêu của đề tài bao gồm:

- Xây dựng quy trình xử lý dữ liệu ảnh từ đầu đến cuối.
- Khảo sát các phương pháp trích xuất đặc trưng thủ công (HOG, SIFT) kết hợp PCA.
- So sánh hiệu quả các mô hình học máy cổ điển.
- Đánh giá chất lượng mô hình theo Accuracy, Precision, Recall, F1-score và thời gian huấn luyện/suy luận.

1.4 Kế hoạch triển khai

Quy trình thực hiện được tổ chức theo các bước chính sau, tương ứng với cấu trúc của notebook:

- **1 – Thiết lập môi trường và cấu hình ban đầu:** Chuẩn bị thư viện, đường dẫn dữ liệu, tham số chung và các hàm hỗ trợ để đảm bảo toàn bộ thí nghiệm được tái lập nhất quán.
- **2 – EDA (Exploratory Data Analysis):** Thực hiện phân tích khám phá dữ liệu theo các tiểu mục trong notebook:
  - **2.1** Cấu trúc bộ dữ liệu.

  - **2.2** Phân phối nhãn của tập dữ liệu.
  - **2.3** Phân tích kích thước ảnh.
  - **2.4** Phân tích kênh màu và cường độ pixel.
  - **2.5** Phân tích kích thước file ảnh.
  - **2.6** Trực quan hóa dữ liệu.

- **3 – Tiền xử lý và trích đặc trưng HOG + SIFT:** Tiền xử lý ảnh đầu vào, xây dựng đặc trưng thủ công và chuẩn bị dữ liệu đặc trưng phục vụ huấn luyện.
- **4 – Hoàn thiện tập đặc trưng HOG + SIFT:** Chuẩn hóa quy trình trích đặc trưng, tổ chức dữ liệu đầu vào cho các mô hình phân loại và sẵn sàng cho bước thực nghiệm.
- **5 – Thực nghiệm so sánh mô hình (5.1–5.6):**
  - **5.1** So sánh HOG + SVM và SIFT + SVM.
  - **5.2** HOG + Random Forest + PCA.
  - **5.3** HOG + Decision Tree + PCA.
  - **5.4** HOG + SVM + PCA.
  - **5.5** HOG + XGBoost + PCA.
  - **5.6** HOG + MLP + PCA.

  Mỗi thí nghiệm được đánh giá theo Accuracy, Precision, Recall, F1-score và thời gian huấn luyện/suy luận để bảo đảm so sánh công bằng.
- **6 – Tổng hợp kết quả và rút ra nhận xét:** Từ các thí nghiệm trên, nhóm tổng hợp kết quả, phân tích ưu/nhược điểm của từng hướng kết hợp đặc trưng – mô hình, từ đó đề xuất cấu hình phù hợp cho bài toán phân loại ảnh MRI não.

1.5 Phạm vi thực hiện

Báo cáo tập trung vào pipeline machine learning truyền thống (không dùng deep learning), nhằm làm rõ tác động của từng bước trong quy trình xử lý ảnh và huấn luyện mô hình. Các thực nghiệm được giới hạn trong dữ liệu BRISC 2025, với cùng thiết lập chia train/test theo cấu trúc dataset gốc để đảm bảo khả năng đối chiếu kết quả.

2 Tổng quan về tập dữ liệu

2.1 Mô tả dữ liệu

Tập dữ liệu sử dụng là **BRISC (BRain tumor Image Segmentation and Classification)** được công bố vào năm 2026. Dữ liệu bao gồm các ảnh MRI não 2D đơn lớp (single-slice) được lưu dưới dạng JPEG.
Đặc điểm quan trọng của BRISC là tất cả các ảnh đều thuộc loại **MRI trọng yếu T1 có tiêm thuốc tương phản (contrast-enhanced T1-weighted MRI)**. Các tác giả đã loại bỏ các ảnh T2-weighted để tập trung vào khả năng làm nổi bật ranh giới khối u một cách hiệu quả nhất của chuỗi xung T1. Tập dữ liệu được phân loại thành 4 lớp:

- **Glioma** (U tế bào thần kinh đệm).
- **Meningioma** (U màng não).
- **Pituitary** (U tuyến yên).
- **Non-tumorous** (Không có u): Bao gồm cả não khỏe mạnh hoàn toàn và các trường hợp có tổn thương không phải u như áp xe hoặc nang.

2.2 Góc chụp và phân phối cắt ảnh

BRISC cung cấp sự đa dạng về góc nhìn giải phẫu, giúp mô hình đạt được khả năng tổng quát hóa tốt hơn trên nhiều mặt cắt khác nhau. Dữ liệu được thu thập trên 3 mặt phẳng hình ảnh chính:

- **Axial** (Mặt cắt ngang).
- **Coronal** (Mặt cắt trán).
- **Sagittal** (Mặt cắt dọc).

Phân phối giữa các mặt cắt này được thiết kế gần như đồng nhất để tránh hiện tượng thiên kiến mô hình (model bias).

2.3 Quy mô và cấu trúc dữ liệu

Tập dữ liệu bao gồm tổng cộng 6.000 hình ảnh MRI. Quy mô này được chia cụ thể như sau:

- **Tập huấn luyện (Train):** 5.000 ảnh.
- **Tập kiểm tra (Test):** 1.000 ảnh.

Dữ liệu được tổ chức theo cấu trúc thư mục lớp, giúp thuận tiện cho các bài toán phân loại đa lớp (classification) và phân vùng ảnh (segmentation).

2.4 Một số hướng tiếp cận hiện đại cho bài toán này

Các tác giả paper đã thiết lập các mốc benchmark sử dụng nhiều kiến trúc học sâu tiên tiến. Dưới đây là kết quả tốt nhất của một số dòng kiến trúc tiêu biểu để so sánh:
Trong đó, **EfficientNetB0** cho thấy hiệu năng vượt trội và độ ổn định cao nhất trên cả 4 lớp dữ liệu.

Kiến trúc	Precision	Recall	F1-Score	Accuracy
EfficientNetB0	0.9923	0.9929	0.9926	0.9920
ResNet50	0.9836	0.9836	0.9834	0.9820
VGG16	0.9722	0.9720	0.9714	0.9692
MobileNetV3	0.9448	0.9537	0.9475	0.9442

Table 1: Kết quả hiệu năng rút gọn của các mô hình học sâu trên tập dữ liệu BRISC.

2.5 Định hướng của nhóm trong báo cáo này

Mặc dù các mô hình học sâu đạt kết quả rất cao, nhóm xác định mục tiêu trọng tâm là **thực hiện và phân tích các phương pháp học máy truyền thống** (HOG, SIFT kết hợp SVM, Random Forest,...) để làm rõ giá trị của việc trích xuất đặc trưng thủ công và tạo baseline so sánh với các nghiên cứu hiện đại.

3 Phân tích khám phá dữ liệu (EDA)

Phần EDA được thực hiện nhằm kiểm tra cấu trúc dữ liệu, mức độ cân bằng nhãn và các đặc tính thống kê quan trọng trước khi huấn luyện.

3.1 Cấu trúc bộ dữ liệu

Nhóm phân tích cấu trúc dữ liệu theo hai tập *train/test*, số lượng mẫu theo từng lớp và số kênh màu của ảnh.

Table 2: Quy mô dữ liệu theo từng lớp

Lớp	**Train**	**Tỉ lệ train (%)**	**Test**	**Tỉ lệ test (%)**
no_tumor	1067	21.3	140	14.0
glioma	1147	22.9	254	25.4
meningioma	1329	26.6	306	30.6
pituitary	1457	29.1	300	30.0
Tổng	**5000**	**100.0**	**1000**	**100.0**

Nhận xét: Dữ liệu có quy mô tương đối lớn cho bài toán phân loại ảnh MRI (6000 ảnh), với cấu trúc thư mục lớp rõ ràng và thuận lợi cho pipeline học máy truyền thống. Tất cả ảnh ở định dạng 3 kênh màu, tuy nhiên mức tương quan kênh rất cao (phân tích ở Mục 4.4) cho thấy bản chất gần ảnh xám.

3.2 Phân phối nhãn

Nhóm kiểm tra số lượng mẫu theo từng lớp trên train/test để đánh giá mức độ cân bằng dữ liệu.

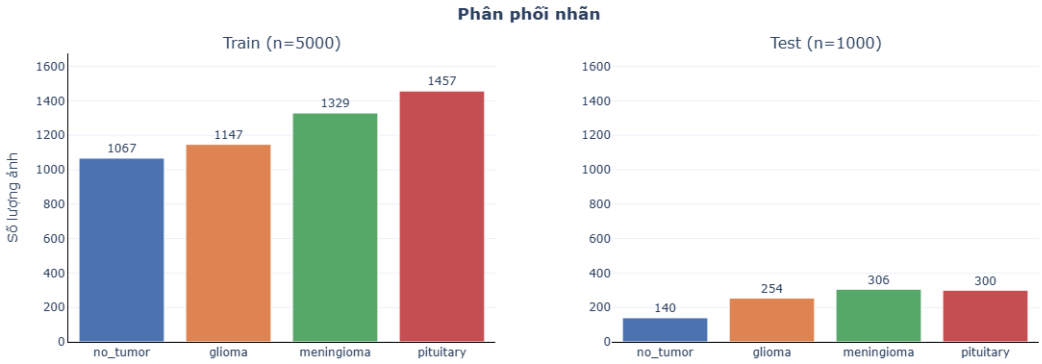

Figure 1: Phân phối nhãn trên tập train và test

Nhận xét: Biểu đồ cho thấy dữ liệu không cân bằng tuyệt đối nhưng mức lệch còn nhẹ (1.37x), đủ an toàn để huấn luyện baseline mà không cần kỹ thuật tái lấy mẫu quá mạnh. Dù vậy, nhóm vẫn cần theo dõi macro-Precision/Recall/F1 ở các bước thực nghiệm để tránh thiên vị về lớp nhiều mẫu.

3.3 Phân tích kích thước ảnh

Nhóm thống kê width/height, trực quan bằng histogram và scatter để quan sát sự đa dạng về kích thước ảnh trước khi resize.

Figure 2: Phân phối width/height của ảnh train

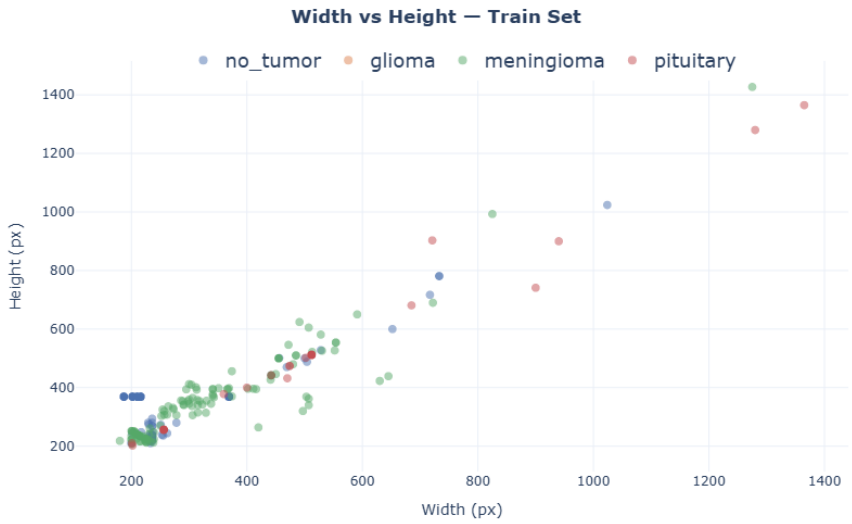

Figure 3: Tương quan width và height trên tập train

Nhận xét: Phần lớn ảnh đã tập trung tại 512×512, nhưng vẫn tồn tại các ảnh kích thước lớn/nhỏ khác biệt rõ rệt. Vì vậy, bước resize về cùng chuẩn là bắt buộc để tránh lỗi khi vector hóa đặc trưng và giúp các mô hình cổ điển nhận đầu vào đồng nhất.

Table 3: Thống kê kích thước ảnh (train)

Thống kê	Width	Height
count	5000.000000	5000.000000
mean	475.105000	485.889600
std	93.855603	69.378908
min	180.000000	202.000000
25%	512.000000	512.000000
50%	512.000000	512.000000
75%	512.000000	512.000000
max	1365.000000	1427.000000

Table 4: Tỉ lệ ảnh đã ở kích thước chuẩn

Chỉ số	Giá trị
Tỉ lệ ảnh 512×512	82.4%

3.4 Phân tích kênh màu và cường độ pixel

Nhóm phân tích thống kê theo từng kênh RGB và đo tương quan giữa các kênh để xem mức độ gần-grayscale của ảnh MRI.

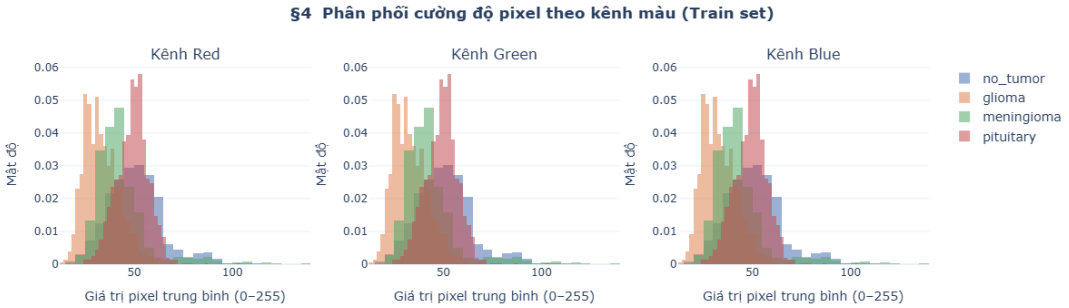

Figure 4: Phân phối cường độ pixel theo kênh màu trên tập train

Nhận xét: Ba histogram gần như chồng khít và hệ số tương quan đạt 1.000 cho thấy ảnh MRI trong tập dữ liệu gần như ảnh xám được lưu ở định dạng RGB. Điều này phù hợp với đặc trưng ảnh y khoa, đồng thời gợi ý rằng trích đặc trưng dựa hình dạng/biên (HOG, SIFT) là lựa chọn hợp lý hơn so với đặc trưng phụ thuộc màu.

3.5 Phân tích kích thước file

Nhóm trực quan phân phối kích thước file theo lớp nhằm phát hiện bất thường và outlier.

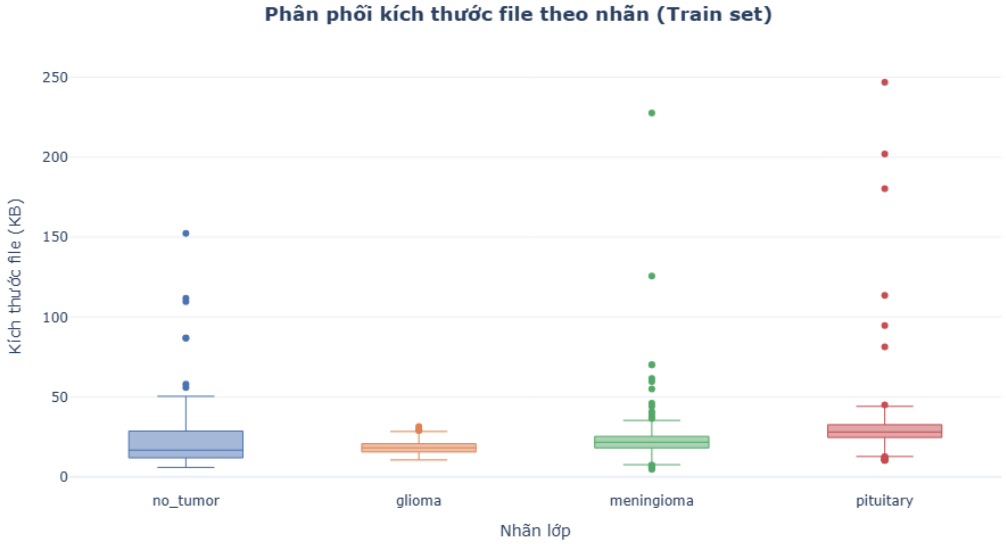

Figure 5: Phân phối kích thước file theo từng nhãn (train)

Table 5: Thống kê kích thước file theo nhãn (KB)

Lớp	Mean	Median	Std	Min	Max
glioma	18.44	18.26	3.70	10.66	31.48
meningioma	22.09	21.76	8.74	4.80	227.59
no_tumor	20.88	16.81	12.34	6.00	152.35
pituitary	28.87	28.13	10.33	10.37	246.90

Nhận xét: Lớp *pituitary* có kích thước file trung bình lớn nhất, trong khi *glioma* ổn định hơn (độ lệch chuẩn thấp). Sự xuất hiện của nhiều outlier rất lớn ở *pituitary*, *meningioma* và *no_tumor* cho thấy mức độ đa dạng mạnh về vùng quan tâm và mức nén ảnh, vì vậy cần tiền xử lý nhất quán để giảm biến thiên không mong muốn.

3.6 Trực quan mẫu dữ liệu

Nhóm hiển thị ảnh mẫu theo từng lớp để kiểm tra nhanh chất lượng dữ liệu và độ đa dạng hình thái.

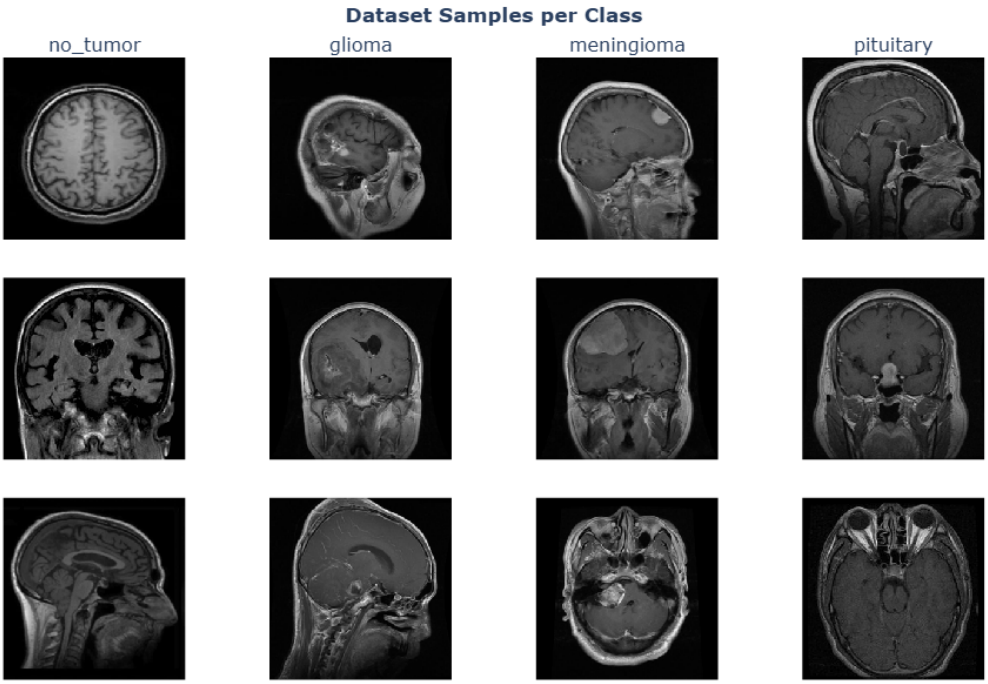

Figure 6: Một số ảnh mẫu theo từng lớp dữ liệu

Nhận xét: Ảnh mẫu cho thấy khác biệt rõ về hình thái giữa các lớp và đa dạng về mặt phẳng cắt (axial/coronal/sagittal). Tuy nhiên, vẫn có các trường hợp ranh giới tổn thương mờ hoặc cấu trúc giải phẫu tương tự giữa các lớp, xác nhận bài toán có độ khó thực tế và cần kết hợp đặc trưng đủ giàu thông tin để phân biệt.

4 Phương pháp thực hiện

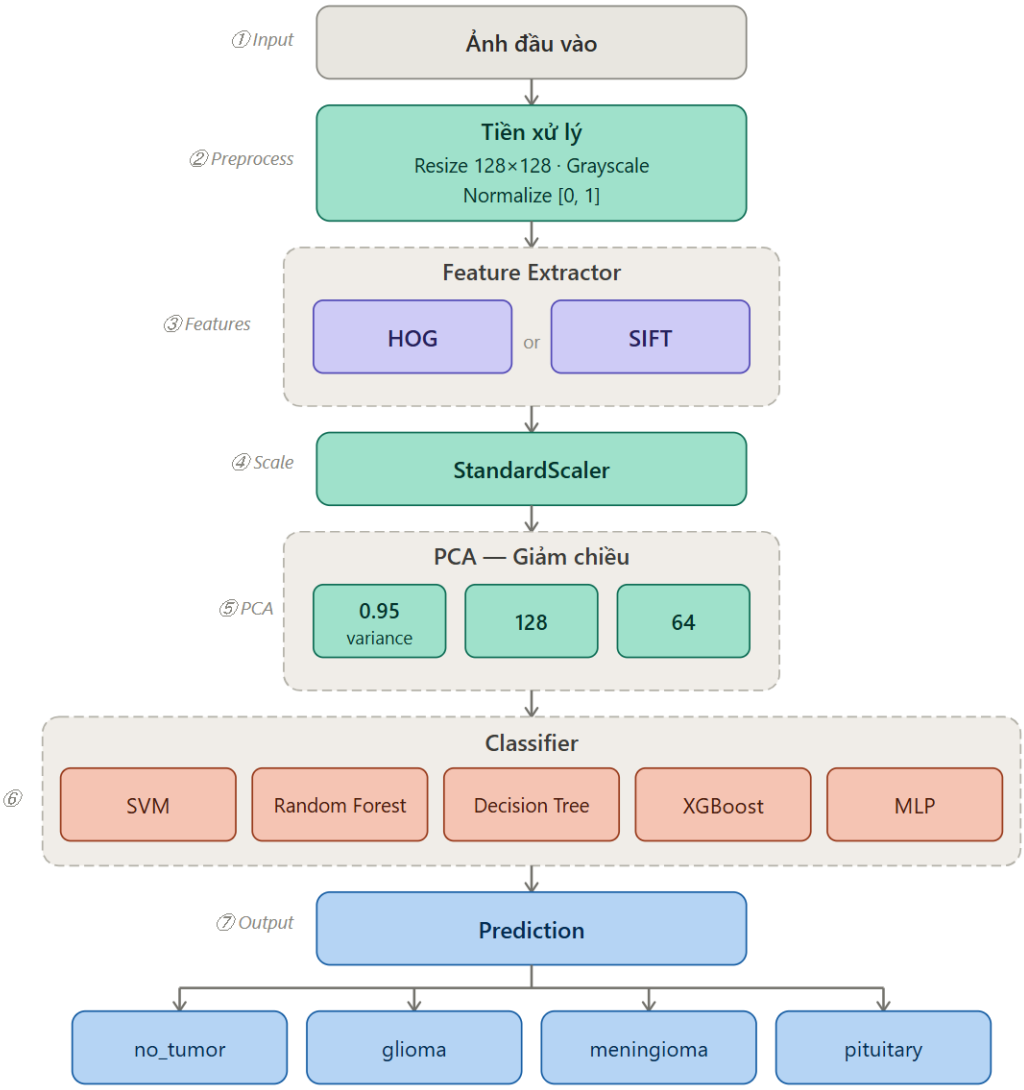

Figure 7: Pipeline

4.1 Tiền xử lý

Pipeline áp dụng các bước tiền xử lý chính:

- Resize ảnh về kích thước 128×128.
- Chuyển ảnh về grayscale cho các bước trích đặc trưng thủ công.
- Chuẩn hóa dữ liệu đầu vào.

4.2 Trích xuất đặc trưng

4.2.1 HOG

Histogram of Oriented Gradients (HOG) là phương pháp trích xuất đặc trưng thủ công nhằm biểu diễn cấu trúc hình dạng của ảnh thông qua phân bố hướng gradient cục bộ. Thay vì sử dụng trực tiếp cường độ điểm ảnh, HOG tập trung vào các thay đổi biên và đường viền, do đó đặc biệt hữu ích cho các bài toán phân loại ảnh y tế khi thông tin hình thái là tín hiệu quan trọng.

a. Ý tưởng cốt lõi

Với mỗi điểm ảnh, HOG tính gradient theo hai trục không gian, sau đó chuyển sang biểu diễn độ lớn và hướng gradient. Các hướng gradient được gom vào histogram trong từng ô nhỏ (cell), rồi chuẩn hóa theo từng khối (block) để tăng độ bền vững trước thay đổi độ sáng và tương phản. Giả sử gradient theo trục ngang và dọc lần lượt là G_x, G_y, ta có:

$$m(x,y) = \sqrt{G_x^2 + G_y^2}, \quad \theta(x,y) = \arctan\left(\frac{G_y}{G_x}\right) \tag{1}$$

trong đó $m(x,y)$ là độ lớn gradient và $\theta(x,y)$ là hướng gradient tại điểm ảnh (x,y).

b. Các bước trích xuất HOG

1. **Tính gradient:** ảnh đầu vào được lọc đạo hàm theo hai trục để thu được G_x, G_y.
2. **Chia cell:** ảnh được chia thành các ô nhỏ (ví dụ 8×8 pixel).
3. **Lập histogram hướng:** trong mỗi cell, mỗi pixel bỏ phiếu vào bin hướng tương ứng, trọng số là độ lớn gradient $m(x,y)$.
4. **Chuẩn hóa block:** ghép nhiều cell thành một block (ví dụ 2×2 cell), rồi chuẩn hóa vector histogram để giảm ảnh hưởng chiếu sáng.
5. **Nối vector đặc trưng:** toàn bộ histogram đã chuẩn hóa được ghép thành một vector HOG cố định cho ảnh.

Trong pipeline thực nghiệm, cấu hình HOG sử dụng 9 hướng (`orientations=9`), kích thước cell 8×8, block 2×2, và chuẩn hóa `L2-Hys`. Đây là cấu hình cân bằng tốt giữa khả năng biểu diễn hình thái và chi phí tính toán.

c. Ưu điểm và hạn chế

Ưu điểm: HOG đơn giản, dễ triển khai, diễn giải tốt và thường hiệu quả với bài toán phân loại ảnh dựa trên biên/đường viền.
Hạn chế: HOG không học đặc trưng ngữ nghĩa mức cao như mô hình học sâu, nhạy với biến dạng hình học mạnh và có thể tạo vector chiều cao nếu không kết hợp giảm chiều.
Trong bối cảnh phân loại ảnh MRI não, HOG phù hợp để mô tả các cấu trúc biên của vùng tổn thương. Khi kết hợp với PCA và các bộ phân loại như SVM, Decision Tree, Random Forest hoặc MLP, đặc trưng HOG tạo nền tảng ổn định cho so sánh thực nghiệm giữa các mô hình.

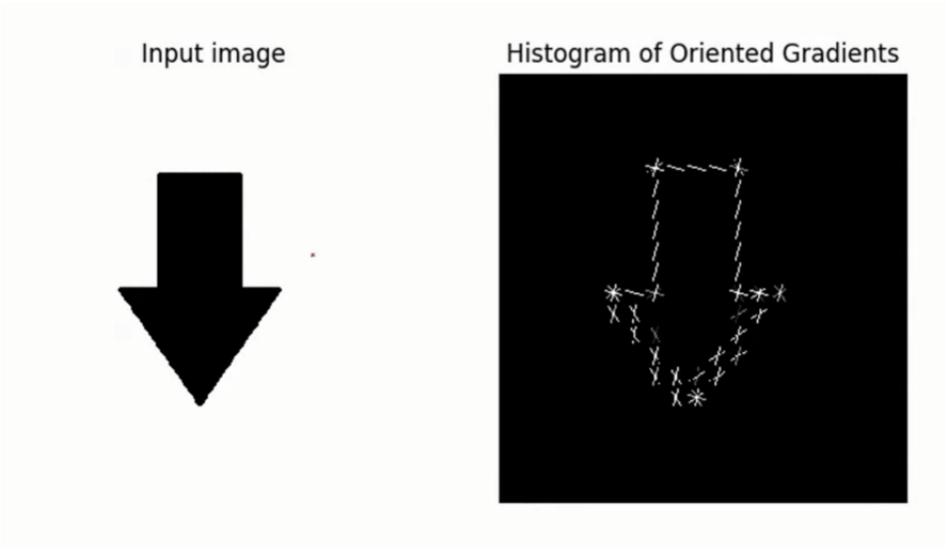

Figure 8: Minh họa HOG: bên trái là ảnh đầu vào, bên phải là biểu diễn hướng gradient (Histogram of Oriented Gradients), nhấn mạnh các biên và cấu trúc hình dạng chính.

4.2.2 Phương pháp SIFT trong trích xuất đặc trưng ảnh

SIFT (Scale-Invariant Feature Transform) là một phương pháp trích xuất đặc trưng truyền thống được đề xuất bởi David Lowe nhằm phát hiện và mô tả các điểm đặc trưng nổi bật trên ảnh. Khác với các đặc trưng dựa trực tiếp trên giá trị điểm ảnh, SIFT biểu diễn ảnh thông qua tập hợp các keypoint và vector đặc trưng tương ứng. Phương pháp này đặc biệt phù hợp với các bài toán thị giác máy tính cổ điển như nhận dạng đối tượng, ghép ảnh và phân loại ảnh.
Ưu điểm quan trọng của SIFT là tính bất biến đối với thay đổi tỉ lệ, phép quay và tương đối bền vững trước sự thay đổi về độ sáng, góc nhìn hoặc nhiễu. Vì vậy, khi ảnh trong tập dữ liệu có sự khác biệt về kích thước hoặc hướng của đối tượng, SIFT vẫn có thể phát hiện được các đặc trưng tương tự.
Quá trình trích xuất đặc trưng bằng SIFT gồm bốn giai đoạn chính:

1. **Phát hiện điểm đặc trưng theo nhiều tỉ lệ**

   Ý tưởng cốt lõi của SIFT là tìm các điểm cực trị trong không gian nhiều tỉ lệ nhằm đảm bảo tính bất biến theo tỉ lệ của đặc trưng. Không gian tỉ lệ được xây dựng bằng cách làm trơn ảnh với bộ lọc Gaussian ở nhiều mức độ khác nhau. Sau đó, SIFT sử dụng phép Difference of Gaussian (DoG) để xấp xỉ đạo hàm bậc hai của ảnh, từ đó phát hiện các điểm cực đại và cực tiểu cục bộ trong không gian ba chiều (x, y, σ). Những điểm này được xem là các ứng viên cho các điểm đặc trưng.

2. **Loại bỏ các điểm không ổn định**

   Sau khi phát hiện các keypoint ứng viên, SIFT tiếp tục loại bỏ những điểm có độ tương phản thấp hoặc nằm trên các biên mạnh. Những điểm này thường không ổn định và dễ gây sai lệch khi phân loại. Bước này giúp tập trung vào các vùng chứa nhiều thông tin đặc trưng hơn.

3. **Gán hướng cho keypoint**

Để đạt được tính bất biến theo phép xoay, SIFT tính toán gradient cường độ tại các điểm lân cận của mỗi keypoint. Từ các giá trị gradient này, thuật toán xây dựng một histogram hướng gradient. Hướng có giá trị lớn nhất trong histogram sẽ được gán làm hướng chính của điểm đặc trưng. Trong một số trường hợp, nếu có nhiều hướng nổi bật, thuật toán có thể tạo ra nhiều keypoint tại cùng một vị trí nhưng với các hướng khác nhau.

4. **Tạo descriptor cho từng keypoint**

   Vùng lân cận quanh mỗi keypoint được chia thành lưới 4×4. Trong mỗi ô, SIFT xây dựng histogram gồm 8 hướng gradient. Vì vậy, descriptor cuối cùng có kích thước:

$$4 \times 4 \times 8 = 128$$

   tức là mỗi keypoint được biểu diễn bởi một vector đặc trưng gồm 128 phần tử. Vector này mô tả cấu trúc cục bộ của ảnh xung quanh keypoint.

Trong bài toán phân loại ảnh, số lượng keypoint giữa các ảnh thường không giống nhau. Tuy nhiên, các mô hình học máy như SVM, Random Forest, Decision Tree, XGBoost hoặc MLP yêu cầu đầu vào có kích thước cố định. Do đó, sau khi trích xuất các descriptor SIFT, cần chuyển tập descriptor của mỗi ảnh thành một vector đặc trưng có cùng số chiều.
Một cách tiếp cận phổ biến là sử dụng mô hình Bag of Visual Words (BoVW). Trước tiên, toàn bộ descriptor SIFT của tập huấn luyện được gom lại và phân cụm bằng thuật toán K-means để tạo ra K "từ thị giác" (visual words). Sau đó, mỗi ảnh được biểu diễn bằng histogram số lần xuất hiện của các visual words:

$$\mathbf{h} = [h_1, h_2, \ldots, h_K]$$

trong đó h_i là số lượng descriptor của ảnh thuộc cụm thứ i. Histogram này có kích thước cố định nên có thể được sử dụng làm đầu vào cho các mô hình phân loại.
So với HOG, SIFT tập trung vào các điểm đặc trưng cục bộ nổi bật, trong khi HOG mô tả phân bố gradient trên toàn bộ ảnh. Vì vậy, SIFT thường hoạt động tốt hơn khi đối tượng trong ảnh có sự thay đổi về vị trí, tỉ lệ hoặc góc quay. Tuy nhiên, SIFT có chi phí tính toán cao hơn và cần thêm bước xây dựng Bag of Visual Words để tạo vector đặc trưng cố định. Trong thực nghiệm, việc so sánh SIFT và HOG kết hợp với các bộ phân loại như SVM, Random Forest, Decision Tree, XGBoost và MLP sẽ cho thấy mức độ phù hợp của từng phương pháp đối với tập dữ liệu ảnh đang xét.

4.3 Giảm chiều

Sau bước trích xuất đặc trưng, các vector đặc trưng thu được từ HOG có số chiều khá lớn, dẫn đến chi phí tính toán tăng và làm mô hình dễ bị ảnh hưởng bởi nhiễu hoặc các thành phần dư thừa. Vì vậy, nhóm sử dụng **Principal Component Analysis (PCA)** như một kỹ thuật giảm chiều tuyến tính để nén không gian đặc trưng trước khi đưa vào các bộ phân loại.

4.3.1 Principal Component Analysis

a. Mục tiêu của PCA

PCA là phương pháp biến đổi tuyến tính nhằm biểu diễn dữ liệu ban đầu trong một hệ trục tọa độ mới sao cho:

- Trục thứ nhất giữ lại lượng phương sai lớn nhất của dữ liệu;

- Các trục tiếp theo lần lượt giữ lại phần phương sai còn lại lớn nhất, đồng thời trực giao với các trục trước đó.

Nói cách khác, PCA tìm cách chiếu dữ liệu từ không gian nhiều chiều sang một không gian thấp chiều hơn nhưng vẫn bảo toàn được phần lớn thông tin quan trọng nhất. Điều này đặc biệt phù hợp với bài toán phân loại ảnh MRI khi đặc trưng HOG thường có số chiều lớn và chứa nhiều thành phần tương quan với nhau.

b. Chuẩn hóa và ma trận hiệp phương sai

Giả sử dữ liệu đầu vào sau chuẩn hóa được biểu diễn bởi ma trận $X \in \mathbb{R}^{n \times d}$, trong đó n là số mẫu và d là số đặc trưng. Bước đầu tiên của PCA là đưa dữ liệu về dạng có trung bình bằng 0 trên từng chiều đặc trưng. Sau đó, ta xây dựng ma trận hiệp phương sai:

$$\Sigma = \frac{1}{n} X^T X \tag{2}$$

Ma trận này mô tả mức độ biến thiên và tương quan giữa các chiều đặc trưng. Mục tiêu của PCA là tìm các hướng chiếu mà tại đó dữ liệu có độ phân tán lớn nhất, vì những hướng này thường chứa thông tin phân biệt quan trọng hơn.

c. Trị riêng, vector riêng và các thành phần chính

Các *principal components* được xác định thông qua bài toán trị riêng của ma trận hiệp phương sai:

$$\Sigma v_i = \lambda_i v_i \tag{3}$$

trong đó:

- v_i là vector riêng, biểu diễn một phương chiếu mới trong không gian đặc trưng;
- λ_i là trị riêng tương ứng, phản ánh lượng phương sai mà phương v_i giữ lại.

Các vector riêng được sắp xếp theo thứ tự giảm dần của trị riêng. Khi đó, các thành phần chính đầu tiên là những hướng quan trọng nhất của dữ liệu. Nếu chọn k thành phần chính đầu tiên với $k < d$, ta thu được ma trận chiếu $W_k = [v_1, v_2, \ldots, v_k]$, và dữ liệu sau giảm chiều được tính bởi:

$$Z = XW_k \tag{4}$$

trong đó $Z \in \mathbb{R}^{n \times k}$ là biểu diễn mới của dữ liệu trong không gian thấp chiều.

d. Tiêu chí lựa chọn số thành phần chính

Trong thực tế, số thành phần chính có thể được chọn theo hai cách phổ biến:

- Chọn cố định số chiều đầu ra, ví dụ $k = 128, 64, 32$;
- Chọn theo tỉ lệ phương sai tích lũy cần giữ lại, ví dụ 90% hoặc 95%.

Tỉ lệ phương sai tích lũy của k thành phần đầu được xác định bởi:

$$\text{Explained Variance Ratio}(k) = \frac{\sum_{i=1}^{k} \lambda_i}{\sum_{j=1}^{d} \lambda_j} \tag{5}$$

Tiêu chí này giúp cân bằng giữa hai mục tiêu: giảm số chiều càng nhiều càng tốt và vẫn giữ lại phần lớn thông tin hữu ích phục vụ phân loại.

e. Ý nghĩa của PCA trong bài toán

Trong bài toán phân loại ảnh MRI não, PCA đóng vai trò quan trọng ở cả khía cạnh tính toán lẫn chất lượng mô hình. Thứ nhất, việc giảm chiều giúp rút ngắn thời gian huấn luyện và suy luận, đặc biệt đối với các mô hình nhạy với số chiều đầu vào như SVM, MLP hay XGBoost. Thứ hai, PCA giúp loại bỏ bớt các thành phần nhiễu hoặc dư thừa trong đặc trưng HOG, từ đó làm nổi bật hơn các cấu trúc biến thiên chính liên quan đến hình dạng và biên của tổn thương. Thứ ba, việc làm việc trong không gian thấp chiều còn giúp quá trình thực nghiệm giữa các mô hình trở nên ổn định và công bằng hơn.

f. Hạn chế của PCA

Mặc dù hiệu quả, PCA vẫn có một số hạn chế. Trước hết, đây là phương pháp giảm chiều tuyến tính nên có thể chưa biểu diễn tốt các cấu trúc phi tuyến phức tạp trong dữ liệu. Ngoài ra, PCA tối ưu theo tiêu chí giữ phương sai lớn nhất chứ không trực tiếp tối ưu cho mục tiêu phân loại, nên không phải mọi thành phần có phương sai cao đều là thành phần phân biệt lớp tốt nhất. Tuy vậy, trong bối cảnh bài toán này, PCA vẫn là lựa chọn phù hợp nhờ tính đơn giản, hiệu quả và khả năng tích hợp tốt với pipeline học máy truyền thống.

4.4 Mô hình phân loại

4.4.1 SVM

Support Vector Machine được nhóm lựa chọn là bộ phân loại (classifier) chủ đạo trong các kịch bản thực nghiệm từ 5.1 đến 5.4. Đây là một thuật toán học máy có giám sát với khả năng xây dựng các ranh giới phân loại tối ưu, đặc biệt hiệu quả khi làm việc với các không gian đặc trưng trích xuất từ HOG và SIFT.

a. Nguyên lý tối ưu hóa lề (Margin Maximization)

Mục tiêu của SVM là tìm kiếm một siêu phẳng tách biệt các lớp dữ liệu sao cho khoảng cách từ siêu phẳng đến các điểm dữ liệu gần nhất là lớn nhất. Phương trình siêu phẳng được xác định bởi:

$$f(x) = w^T x + b = 0 \tag{6}$$

Việc tối đa hóa lề giúp mô hình SVM đạt được độ ổn định cao, giảm thiểu sai số khi dự đoán trên tập dữ liệu kiểm tra ngay cả khi dữ liệu có nhiễu.

b. Hàm nhân Radial Basis Function và các tham số

Dựa trên cấu trúc pipeline thực hiện trong code, nhóm tập trung sử dụng hàm nhân **RBF (Gaussian Kernel)**. Đây là lựa chọn tối ưu để xử lý các đặc trưng phi tuyến tính phức tạp của hình ảnh y tế.

Hàm nhân RBF được tính toán theo công thức:

$$K(x_i, x_j) = \exp(-\gamma||x_i - x_j||^2) \tag{7}$$

Trong các thực nghiệm (kịch bản 5.1 và 5.4), hai tham số quan trọng nhất đã được thiết lập như sau:

- **Tham số $C = 1.0$ (Regularization):** Đây là tham số điều chuẩn giúp cân bằng giữa việc tối đa hóa lề và sai số huấn luyện. Với giá trị 1.0, mô hình đạt được sự cân bằng (Soft Margin), cho phép một độ trễ nhất định để tránh hiện tượng quá khớp (overfitting).
- **Tham số γ (Gamma) = "scale":** Tham số này điều khiển tầm ảnh hưởng của một điểm dữ liệu huấn luyện đơn lẻ. Khi đặt là "scale", giá trị γ sẽ tự động tính toán dựa trên số lượng đặc trưng (1/(n_features × X.var())), giúp mô hình thích ứng tốt với cả đặc trưng HOG nguyên bản và đặc trưng đã qua giảm chiều PCA.

c. Kết hợp SVM với Pipeline giảm chiều dữ liệu

Theo kịch bản thực nghiệm 5.4, SVM không làm việc trực tiếp trên toàn bộ vector đặc trưng HOG mà được đặt sau một lớp **Principal Component Analysis** . Việc kết hợp này rất quan trọng vì:

- Giảm số lượng tham số cần tính toán trong ma trận Kernel, từ đó giảm thời gian huấn luyện (*train_time*) và thời gian dự đoán (*inference_time*).
- Loại bỏ các đặc trưng gây nhiễu, giúp siêu phẳng của SVM tập trung vào các thành phần mang lại phương sai (variance) cao nhất (giữ lại 90% đến 95% thông tin như trong code thực nghiệm).

4.4.2 Decision Tree

Cây quyết định là một thuật toán học máy phi tham số có cấu trúc phân cấp, được nhóm sử dụng trong kịch bản thực nghiệm 5.3 để đánh giá hiệu quả phân loại trên các thành phần chính của đặc trưng HOG sau khi qua xử lý PCA.

a. Tiêu chí phân tách Gini (Gini Impurity)

Trong thực nghiệm, nhóm thiết lập tham số `criterion="gini"`. Đây là tiêu chí mặc định và hiệu quả nhất để đo lường độ vẩn đục (impurity) của các nút trong cây. Chỉ số Gini giúp thuật toán xác định đặc trưng và ngưỡng giá trị tối ưu để thực hiện phân nhánh sao cho tập dữ liệu sau khi chia có độ thuần khiết cao nhất.
Công thức tính chỉ số Gini cho một tập dữ liệu D:

$$Gini(D) = 1 - \sum_{i=1}^{C} p_i^2 \tag{8}$$

Trong đó $C = 4$ (tương ứng với 4 loại u não) và p_i là xác suất xuất hiện của lớp i trong tập dữ liệu đó. Việc sử dụng Gini giúp giảm bớt chi phí tính toán (so với Entropy) trong khi vẫn đảm bảo độ chính xác của mô hình.

b. Tối ưu hóa cấu trúc cây và kiểm soát quá khớp

Cây quyết định rất dễ rơi vào tình trạng quá khớp (overfitting) nếu không được giới hạn độ phát triển. Dựa trên lưới tham số (*param_grid*) trong kịch bản 5.3, nhóm đã tiến hành tinh chỉnh các tham số sau:

- **Độ sâu tối đa (`max_depth`):** Thử nghiệm với các giá trị $[None, 10, 5]$. Việc giới hạn độ sâu giúp cây không "học thuộc lòng" những nhiễu nhỏ trong dữ liệu ảnh y tế mà tập trung vào các đặc trưng hình thái tổng quát.
- **Mẫu tối thiểu để phân tách (`min_samples_split`):** Thử nghiệm với các giá trị $[2, 5]$. Tham số này đảm bảo một nút chỉ được phép chia nhỏ nếu nó chứa đủ số lượng mẫu quy định, từ đó ngăn chặn việc hình thành các nút lá quá đặc thù cho một vài mẫu dữ liệu cụ thể.

c. Vai trò của PCA đối với Decision Tree

Một điểm đặc biệt trong kịch bản 5.3 là việc chạy Decision Tree trên các không gian PCA có số chiều khác nhau $(128, 64, 32)$. Điều này mang lại hai lợi ích quan trọng:

1. **Khắc phục nhược điểm của dữ liệu số chiều lớn:** Cây quyết định thường hoạt động kém hiệu quả và dễ bị nhiễu khi vector đặc trưng quá dài (như HOG nguyên bản). PCA giúp cô đọng thông tin vào các trục chính, giúp cây đưa ra các quy tắc phân nhánh logic và chính xác hơn.
2. **Khả năng diễn giải đặc trưng:** Thông qua thuộc tính `feature_importances_`, mô hình cho phép xác định được thành phần PCA nào đóng góp nhiều nhất vào việc phân loại, từ đó giúp nhóm hiểu rõ hơn về cấu trúc của các khối u não trong không gian đặc trưng.

4.4.3 Random Forest

Random Forest là mô hình học máy tổ hợp (ensemble) dựa trên nguyên lý *bagging*, trong đó nhiều cây quyết định được huấn luyện trên các mẫu bootstrap khác nhau và kết hợp lại để đưa ra dự đoán cuối cùng. So với một cây quyết định đơn lẻ, Random Forest thường ổn định hơn, giảm phương sai và hạn chế hiện tượng quá khớp trên dữ liệu ảnh có nhiễu.

a. Cơ chế bagging và bỏ phiếu đa số

Giả sử mô hình gồm B cây quyết định $\{T_1, T_2, \ldots, T_B\}$. Với bài toán phân loại, dự đoán cuối cùng được xác định theo cơ chế bỏ phiếu đa số:

$$\hat{y} = \text{mode}\left(T_1(x), T_2(x), \ldots, T_B(x)\right) \tag{9}$$

Mỗi cây được huấn luyện trên một tập con bootstrap và tại mỗi nút chỉ xét một tập con ngẫu nhiên của đặc trưng. Hai mức ngẫu nhiên này làm giảm tương quan giữa các cây, từ đó cải thiện khả năng tổng quát hóa.

b. Tham số quan trọng trong thực nghiệm

Trong pipeline, Random Forest thường được tối ưu thông qua các siêu tham số chính:

- `n_estimators`: số lượng cây trong rừng; tăng số cây thường giúp ổn định kết quả nhưng làm tăng thời gian huấn luyện/suy luận.

- `max_depth`: giới hạn độ sâu cây nhằm kiểm soát quá khớp.
- `min_samples_split`, `min_samples_leaf`: ràng buộc điều kiện tách nút để tránh các nhánh quá đặc thù.
- `max_features`: số đặc trưng được xét tại mỗi lần tách nút, ảnh hưởng trực tiếp đến độ đa dạng giữa các cây.

c. Vai trò của Random Forest với đặc trưng HOG + PCA

Đặc trưng HOG sau PCA tạo không gian đầu vào có số chiều vừa phải và ít nhiễu hơn. Khi đó, Random Forest có thể học các quy tắc phân tách phi tuyến giữa bốn lớp u não một cách linh hoạt hơn so với mô hình tuyến tính. Đồng thời, thuộc tính `feature_importances_` của mô hình giúp đánh giá thành phần PCA nào đóng góp lớn cho quyết định phân loại, hỗ trợ khả năng diễn giải kết quả.

d. Ưu điểm và hạn chế

Ưu điểm: bền vững với nhiễu, ít nhạy với chuẩn hóa đặc trưng, hiệu quả tốt trên dữ liệu tabular từ HOG/SIFT và dễ diễn giải tương đối thông qua độ quan trọng đặc trưng.
Hạn chế: kích thước mô hình lớn khi số cây cao, chi phí suy luận tăng theo số cây, và khó mô hình hóa các quan hệ rất tinh vi so với các phương pháp boosting mạnh như XGBoost.

4.4.4 XGBoost

XGBoost (eXtreme Gradient Boosting) là phương pháp boosting tăng cường theo gradient, xây dựng mô hình theo kiểu cộng dồn nhiều cây quyết định nông. Khác với bagging của Random Forest, boosting huấn luyện cây mới để sửa sai phần còn lại của các cây trước đó, nhờ vậy thường đạt độ chính xác cao trên dữ liệu có quan hệ phi tuyến phức tạp.

a. Nguyên lý tối ưu theo gradient

Mô hình boosting dạng cây có thể biểu diễn dưới dạng tổng các hàm cây:

$$\hat{y}_i = \sum_{t=1}^{T} f_t(x_i), \quad f_t \in \mathcal{F} \tag{10}$$

Trong đó $\mathcal{F}$ là không gian các cây hồi quy/phân loại. Tại vòng lặp t, XGBoost thêm cây mới f_t để tối thiểu hóa hàm mục tiêu gồm hai phần: sai số dự đoán và điều chuẩn độ phức tạp mô hình:

$$\mathcal{L}^{(t)} = \sum_{i=1}^{n} l\left(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)\right) + \Omega(f_t) \tag{11}$$

với $\Omega(f_t)$ là hạng điều chuẩn giúp hạn chế quá khớp và giữ cho cây có cấu trúc gọn.

b. Các siêu tham số quan trọng

Trong thực nghiệm, hiệu năng của XGBoost phụ thuộc mạnh vào bộ siêu tham số:

- `n_estimators`: số vòng boosting (số cây cộng dồn).
- `learning_rate`: tốc độ học; giá trị nhỏ giúp học ổn định hơn nhưng cần nhiều cây hơn.

- `max_depth`: độ sâu cây cơ sở, ảnh hưởng đến khả năng học quan hệ phi tuyến.
- `subsample`, `colsample_bytree`: lấy mẫu theo hàng/cột để giảm tương quan và tăng khả năng tổng quát hóa.
- `reg_alpha`, `reg_lambda`: điều chuẩn L_1/L_2 nhằm kiểm soát độ phức tạp mô hình.

c. Vai trò của XGBoost trong bài toán phân loại MRI

Với đặc trưng HOG đã được giảm chiều bằng PCA, XGBoost có thể khai thác hiệu quả các mối quan hệ phi tuyến giữa các thành phần chính để cải thiện năng lực phân biệt lớp. So với một cây đơn lẻ, mô hình boosting cho biên quyết định linh hoạt hơn và thường cải thiện các chỉ số *accuracy*, *precision*, *recall* và *f1-score* khi được tinh chỉnh siêu tham số phù hợp.

d. Ưu điểm và hạn chế

Ưu điểm: độ chính xác cao, cơ chế regularization tốt, hỗ trợ xử lý dữ liệu nhiều chiều hiệu quả và có thể khai thác tầm quan trọng đặc trưng.
Hạn chế: nhạy với siêu tham số, thời gian tinh chỉnh có thể lớn, và nguy cơ quá khớp nếu cấu hình cây quá phức tạp hoặc số vòng boosting quá cao.

4.4.5 Multi-Layer Perceptron

Trong kịch bản thực nghiệm 5.6, nhóm sử dụng **mạng nơ-ron truyền thẳng nhiều lớp** (*Multi-Layer Perceptron – MLP*) làm bộ phân loại cho đặc trưng **HOG sau khi giảm chiều bằng PCA**. Khác với các mô hình tuyến tính hoặc dựa trên cây, MLP có khả năng học các ánh xạ phi tuyến giữa đặc trưng đầu vào và nhãn đầu ra, nhờ đó phù hợp với bài toán phân loại ảnh MRI khi ranh giới giữa các lớp không hoàn toàn tách biệt trong không gian đặc trưng. Cấu hình tổng quát của mô hình trong notebook gồm hai tầng ẩn `hidden_layers=(512,256)`, bộ tối ưu **Adam** và cơ chế **early stopping**.

a. Kiến trúc mạng và nguyên lý học phi tuyến

MLP là một mạng nơ-ron *feed-forward*, trong đó mỗi tầng thực hiện phép biến đổi tuyến tính kết hợp với hàm kích hoạt phi tuyến. Với đầu vào là vector đặc trưng PCA ký hiệu x, đầu ra của một tầng ẩn có thể được mô tả như sau:

$$h = \phi(Wx + b) \tag{12}$$

trong đó W là ma trận trọng số, b là vector *bias* và ϕ là hàm kích hoạt phi tuyến. Nhờ chồng nhiều tầng ẩn liên tiếp, mô hình có thể học được các quan hệ đặc trưng phức tạp hơn so với SVM tuyến tính hay Decision Tree đơn lẻ. Với bài toán phân loại 4 lớp ảnh MRI não, tầng đầu ra của mạng sinh ra phân phối xác suất trên các lớp và lớp có xác suất lớn nhất sẽ được chọn làm kết quả dự đoán.

b. Cấu hình huấn luyện trong thực nghiệm

Theo thiết lập thực nghiệm ở Mục 5.2, nhóm áp dụng MLP trên đặc trưng **HOG + PCA** với cấu hình chính gồm hai tầng ẩn kích thước **512** và **256** nút. Việc chọn kiến trúc này nhằm tạo đủ năng lực biểu diễn để mô hình học được các khác biệt hình thái giữa các loại u não, nhưng vẫn giữ chi phí huấn luyện ở mức hợp lý. Bộ tối ưu **Adam** được sử dụng vì có khả năng cập nhật trọng số hiệu quả trên dữ liệu nhiều chiều, hội tụ nhanh và ổn định. Đồng thời, tùy chọn

early_stopping giúp dừng huấn luyện khi chất lượng trên tập validation không còn cải thiện, từ đó hạn chế hiện tượng quá khớp trên dữ liệu huấn luyện.

c. Vai trò của PCA đối với MLP

Việc kết hợp PCA trước MLP có ý nghĩa quan trọng trong pipeline. Thứ nhất, PCA làm giảm số chiều của vector HOG, từ đó giảm số lượng tham số cần học ở tầng đầu vào của mạng nơ-ron và rút ngắn thời gian huấn luyện. Thứ hai, các thành phần chính giữ lại phần lớn phương sai quan trọng của dữ liệu, giúp mô hình tập trung vào các tín hiệu đặc trưng nổi bật thay vì bị ảnh hưởng bởi nhiễu hoặc sự dư thừa giữa các đặc trưng gốc. Trong bối cảnh dữ liệu MRI gần như ảnh xám và đặc trưng HOG nhấn mạnh thông tin biên, sự kết hợp **HOG + PCA + MLP** là một hướng tiếp cận hợp lý để khai thác cả cấu trúc hình dạng lẫn khả năng mô hình hóa phi tuyến của mạng nơ-ron.

d. Ưu điểm và hạn chế

Ưu điểm chính của MLP là khả năng học các quan hệ phi tuyến phức tạp giữa đặc trưng và nhãn, do đó có tiềm năng cải thiện độ chính xác so với một số mô hình cổ điển khi dữ liệu đã được biểu diễn tốt. Tuy nhiên, MLP cũng nhạy cảm với cấu hình siêu tham số như số tầng ẩn, số nút, tốc độ học và điều kiện dừng sớm. Nếu không kết hợp PCA hoặc regularization phù hợp, mô hình có thể bị overfit do số chiều đầu vào lớn. Vì vậy, trong báo cáo này, MLP được xem như một mô hình trung gian giữa học máy truyền thống và học sâu: vẫn làm việc trên đặc trưng thủ công đã trích xuất, nhưng có năng lực biểu diễn mạnh hơn các bộ phân loại cổ điển.

4.5 Tối ưu quy trình thực nghiệm

Nhóm tách bước *prepare dataset* khỏi bước huấn luyện, lưu đặc trưng vào cache (`.npz`) để:

- Tránh trích đặc trưng lặp lại.
- So sánh công bằng giữa các mô hình.
- Tăng tốc quá trình thực nghiệm.

5 Thiết kế thực nghiệm

Các thực nghiệm được tổ chức theo đúng notebook, sử dụng dữ liệu đặc trưng đã cache để đảm bảo nhất quán.

5.1 Thiết lập đánh giá

Các chỉ số đánh giá bao gồm:

- Accuracy, Precision (macro), Recall (macro), F1-score (macro), Train time, Inference time.

5.2 Danh sách thực nghiệm chính

Table 6: Các thực nghiệm trong mục 5 của notebook

Mục	**Đặc trưng**	**Mô hình**	**PCA**	**Cấu hình chính**
5.1	HOG, SIFT(BoVW)	SVM	None	kernel=rbf C=1.0 gamma=scale
5.2	HOG + PCA	Random Forest	0.95, 128, 64	GridSearchCV: n_estimators=[100,200] max_depth=[None,10,20]
5.3	HOG + PCA	Decision Tree	0.95, 128, 64	GridSearchCV: max_depth=[None,10,5] min_samples_split=[2,5] criterion=gini
5.4	HOG + PCA	SVM	0.95, 128, 64	GridSearchCV: C=[0.1,1.0,10] kernel=rbf gamma=scale
5.5	HOG + PCA	XGBoost	128, 64, 32	GridSearchCV: n_estimators=[100,200] max_depth=[20,10,None] learning_rate=0.1 subsample=0.8
5.6	HOG + PCA	MLP	128, 64, 0.95	hidden_layer_sizes=(512,256) activation=relu solver=adam max_iter=300 early_stopping=True

6 Kết quả và so sánh

Phần này tổng hợp đầy đủ kết quả định lượng từ các cell thực nghiệm trong notebook (mục 5.1 đến 5.6). Mỗi bảng tương ứng một nhóm thí nghiệm, với đầy đủ các chỉ số: Accuracy, Precision (macro), Recall (macro), F1-score (macro), Train time và Inference time.

6.1 Kết quả mục 5.1: HOG + SVM và SIFT + SVM

Table 7: Kết quả thí nghiệm 5.1

Thiết lập	PCA	Accuracy	Precision	Recall	F1	Train/Infer (s)
HOG + SVM	None	0.918	0.921976	0.925080	0.921547	109.764977 / 32.615765
SIFT(BoVW) + SVM	None	0.789	0.801156	0.804111	0.801035	3.392293 / 2.300187

6.2 Kết quả mục 5.2: HOG + Random Forest + PCA

Table 8: Kết quả thí nghiệm 5.2

Thiết lập	PCA	Accuracy	Precision	Recall	F1	Train/Infer (s)
HOG + RF + PCA=128	128	0.917	0.923330	0.923931	0.922782	224.405285 / 0.077820
HOG + RF + PCA=64	64	0.887	0.894765	0.897114	0.895047	158.725036 / 0.077538
HOG + RF + PCA=0.95	0.95	0.887	0.898296	0.895644	0.895505	883.068758 / 0.091827

6.2.1 Feature Importance – Random Forest

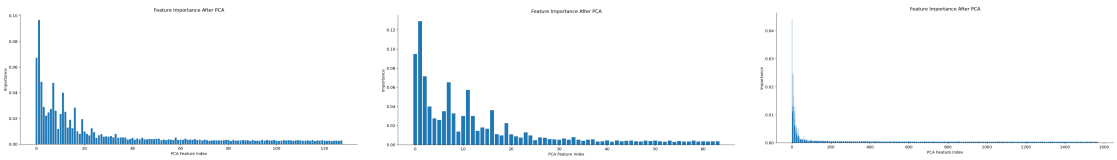

(a) RF với PCA=128 (b) RF với PCA=64 (c) RF với PCA=0.95

Figure 9: Feature importance của mô hình Random Forest theo các cấu hình PCA

6.3 Kết quả mục 5.3: HOG + Decision Tree + PCA

Table 9: Kết quả thí nghiệm 5.3

Thiết lập	PCA	Accuracy	Precision	Recall	F1	Train/Infer (s)
HOG + DT + PCA=128	128	0.824	0.825308	0.834630	0.829559	20.404360 / 0.001060
HOG + DT + PCA=64	64	0.827	0.826486	0.834654	0.830082	10.523545 / 0.001169
HOG + DT + PCA=0.95	0.95	0.803	0.809197	0.816386	0.812436	262.507357 / 0.001841

6.3.1 Feature Importance – Decision Tree

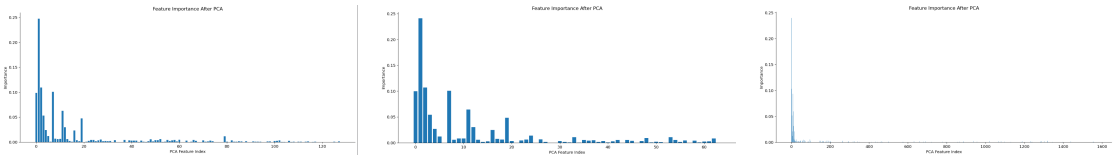

(a) DT với PCA=128 (b) DT với PCA=64 (c) DT với PCA=0.95

Figure 10: Feature importance của mô hình Decision Tree theo các cấu hình PCA

6.4 Kết quả mục 5.4: HOG + SVM + PCA

Table 10: Kết quả thí nghiệm 5.4

Thiết lập	PCA	Accuracy	Precision	Recall	F1	Train/Infer (s)
HOG + SVM + PCA=128	128	0.906	0.903720	0.914658	0.906934	12.852651 / 0.279147
HOG + SVM + PCA=64	64	0.885	0.881605	0.897952	0.886720	9.172444 / 0.193243
HOG + SVM + PCA=0.95	0.95	0.956	0.958708	0.960205	0.959124	287.277244 / 5.913671

6.5 Kết quả mục 5.5: HOG + XGBoost + PCA

Table 11: Kết quả thí nghiệm 5.5

Thiết lập	PCA	Accuracy	Precision	Recall	F1	Train/Infer (s)
HOG + XGBoost + PCA=128	128	0.927	0.932325	0.933622	0.932755	576.296931 / 0.024516
HOG + XGBoost + PCA=64	64	0.925	0.929819	0.931654	0.930445	281.800049 / 0.018638
HOG + XGBoost + PCA=32	32	0.922	0.929279	0.927063	0.927443	146.244813 / 0.024668

6.5.1 Feature Importance – XGBoost

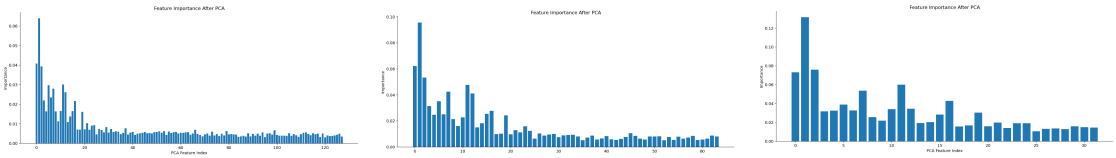

(a) XGBoost với PCA=128 (b) XGBoost với PCA=64 (c) XGBoost với PCA=32

Figure 11: Feature importance của mô hình XGBoost theo các cấu hình PCA

6.6 Kết quả mục 5.6: HOG + MLP + PCA

Table 12: Kết quả thí nghiệm 5.6

Thiết lập	PCA	Accuracy	Precision	Recall	F1	Train/Infer (s)
HOG + MLP + PCA=128	128	0.932	0.932675	0.938776	0.935247	5.654602 / 0.009295
HOG + MLP + PCA=64	64	0.953	0.954933	0.955968	0.955251	7.148280 / 0.008437
HOG + MLP + PCA=0.95	0.95	0.909	0.915623	0.918445	0.915724	17.050505 / 0.032972

6.7 Tóm tắt so sánh

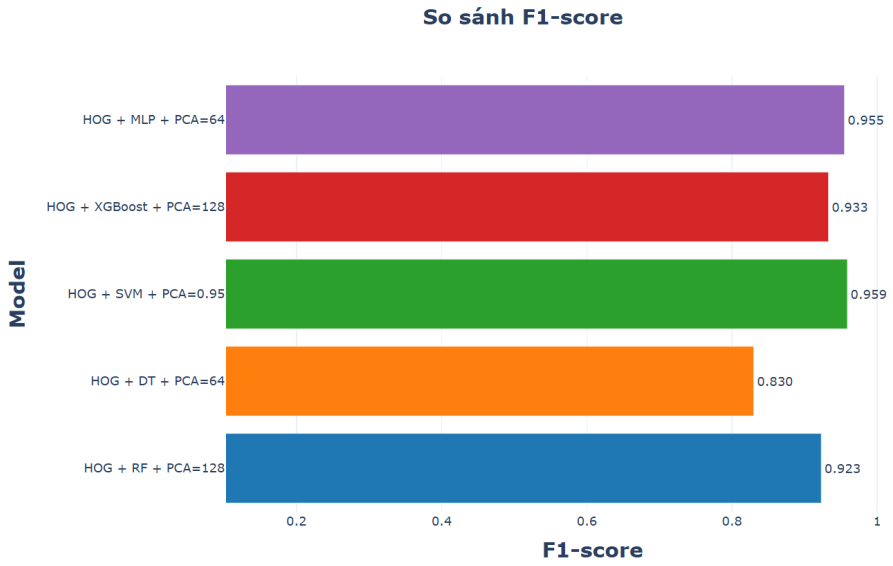

Figure 12: So sánh F1-score (macro) giữa các cấu hình thí nghiệm

- **Decision Tree** cho F1-score thấp nhất. Nguyên nhân chính là mô hình chỉ dựa trên *một cây quyết định*, nên phương sai cao, dễ học quá khớp các nhánh đặc thù của tập huấn luyện và kém ổn định khi tổng quát hóa trên dữ liệu kiểm thử.
- **Random Forest** cải thiện rõ rệt so với Decision Tree do cơ chế *ensemble* nhiều cây và lấy trung bình biểu quyết. Cách kết hợp này giúp giảm phương sai, hạn chế overfitting của từng cây đơn lẻ và tăng độ ổn định của dự đoán.
- **XGBoost** cũng thuộc nhóm *ensemble* và đạt F1-score cao, nhờ cơ chế boosting học tuần tự để sửa sai các mẫu khó. Vì vậy, mô hình có khả năng tối ưu biên quyết định tốt hơn so với cây đơn và duy trì chất lượng phân loại đồng đều giữa các lớp.
- **MLP** đạt F1-score rất cạnh tranh nhờ kiến trúc mạng linh hoạt và khả năng học quan hệ phi tuyến. Với các siêu tham số phù hợp, MLP biểu diễn được các mẫu phức tạp mà các mô hình tuyến tính hoặc cấu trúc đơn giản khó nắm bắt.

- **SVM** là mô hình có F1-score cao nhất trong biểu đồ. Điểm mạnh cốt lõi là nguyên lý *tối đa hóa biên phân tách* cùng *kernel* phi tuyến, giúp mô hình giữ khả năng khái quát tốt và cân bằng giữa các lớp, do đó đạt hiệu quả nổi bật trên thước đo F1-score macro.

Figure 13: So sánh thời gian huấn luyện và suy luận giữa các cấu hình thí nghiệm

- **XGBoost** có thời gian huấn luyện lớn nhất trong nhóm so sánh. Nguyên nhân là cơ chế boosting huấn luyện tuần tự nhiều cây và liên tục cập nhật để sửa sai, nên chi phí tính toán tích lũy cao.
- **SVM** có thời gian huấn luyện cao, chủ yếu do bài toán tối ưu biên phân tách và quá trình tìm tham số tốt nhất. Với dữ liệu kích thước lớn, chi phí huấn luyện của SVM tăng đáng kể.
- **Random Forest** nhanh hơn XGBoost nhưng vẫn tốn thời gian do phải xây dựng nhiều cây. Điểm thuận lợi là các cây có thể huấn luyện song song, nên tốc độ thường ổn định hơn các phương pháp boosting.
- **Decision Tree** có thời gian huấn luyện tương đối thấp vì chỉ học một cây, không cần lặp tối ưu nhiều vòng như SVM/MLP hay cộng dồn nhiều mô hình như ensemble.
- **MLP** là mô hình nhanh nhất trong các cấu hình được chọn, nhờ tối ưu theo gradient với Adam và cơ chế *early stopping*. Điều này giúp rút ngắn thời gian huấn luyện mà vẫn giữ hiệu năng cao.

6.8 Phân tích lỗi

Từ confusion matrix của mô hình tốt nhất, có thể thấy cặp lớp **glioma** và **meningioma** là nhóm dễ nhầm lẫn nhất. Trong khi đó, các lớp **no_tumor** và **pituitary** được phân tách tốt hơn với số lượng dự đoán đúng cao.
Hình dưới đây minh họa trực quan cho phân tích lỗi, gồm: (i) confusion matrix tổng quan và (ii) một số ảnh dự đoán sai tiêu biểu.

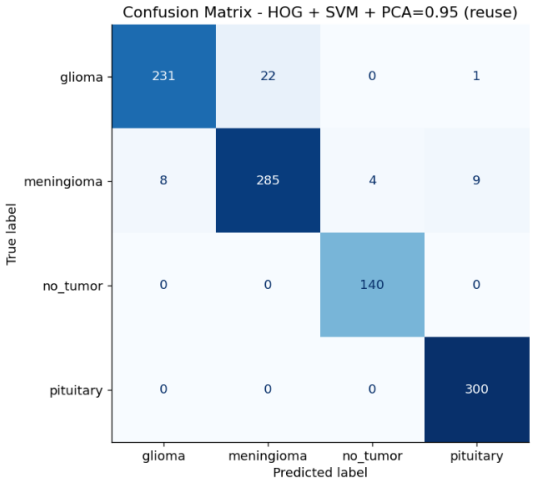

(a) Confusion matrix của mô hình tốt nhất

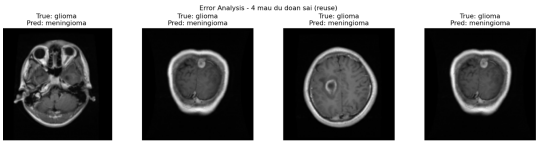

(b) Một số ảnh dự đoán sai tiêu biểu

Figure 14: Phân tích lỗi cho mô hình HOG + SVM + PCA=0.95

7 Kết luận và hướng phát triển

7.1 Kết luận

- Nhóm đã xây dựng một pipeline học máy truyền thống hoàn chỉnh cho bài toán phân loại ảnh MRI u não, gồm tiền xử lý, trích xuất đặc trưng HOG/SIFT, giảm chiều bằng PCA, huấn luyện và đánh giá mô hình.
- Kết quả thực nghiệm cho thấy đặc trưng HOG phù hợp hơn SIFT trong bối cảnh bài toán này, đặc biệt khi kết hợp với các mô hình phân loại mạnh như SVM và MLP.
- Cấu hình tốt nhất là **HOG + SVM + PCA=0.95**, đạt F1-score cao nhất trong toàn bộ các thí nghiệm; bên cạnh đó, **HOG + MLP + PCA=64** cũng cho hiệu năng cạnh tranh và thời gian suy luận thấp.

7.2 Hướng phát triển

- Bổ sung phân tích lỗi chi tiết theo từng lớp thông qua confusion matrix và các mẫu dự đoán sai tiêu biểu.
- Mở rộng không gian siêu tham số và áp dụng các chiến lược tối ưu hiệu quả hơn để cải thiện chất lượng mô hình.
- So sánh thêm với các baseline deep learning và từng bước đóng gói pipeline để phục vụ thử nghiệm triển khai thực tế.

Nguồn tham khảo

[1] BRISC 2025 Brain Tumor MRI Dataset, https://www.kaggle.com/datasets/briscdataset/brisc2025

[2] Scikit-learn Documentation, https://scikit-learn.org/stable/

[3] scikit-image HOG feature documentation, https://scikit-image.org/docs/stable/api/skimage.feature.html#skimage.feature.hog

[4] XGBoost Documentation, https://xgboost.readthedocs.io/

[5] S. Hussain, A. Mansoor, and N. Muhammad, "BRISC: Annotated dataset for brain tumor segmentation and classification," *Scientific Data*, vol. 10, no. 1, p. 587, 2023. https://doi.org/10.1038/s41597-023-02497-2